

1.

(الف)

$^{[A-Z]}$

Regular Expression Javascript flags

`/^[A-Z]/gm` 5 matches

Test String

The quick brown fox jumps over the lazy dog.
For academic inquiries, please contact professor@example.edu or student@university.ac.uk.
Passwords like Strong#Pa\$\$w0rd or SecureP@ssw0r!d are examples of strong

(ب)

$\backslash b[\backslash w. \%+-]+@(?:[\backslash w-]+\backslash.)(?:edu|ac\.[A-Za-z]{2}|edu\.[A-Za-z]{2,3})\backslash b$

Regular Expression Javascript flags

`/\b[\w. \%+-]+@(?:[\w-]+\.[A-Za-z]{2}|edu\.[A-Za-z]{2,3})\b/g` 2 matches

Test String

The quick brown fox jumps over the lazy dog.
For academic inquiries, please contact professor@example.edu or student@university.ac.uk.
Passwords like Strong#Pa\$\$w0rd or SecureP@ssw0r!d are examples of strong

ج

`\b[\w]*[!@#$$%^&*|~]+[\w]*\b`

Regular Expression

Javascript

flags

`/\b[\w]*[!@#$$%^&*|~]+[\w]*\b/gm`

6 matches

Test String

Passwords like Strong#Pa\$\$w0rd or SecureP@ssw0r!d are examples of strong passwords.
The IP address 192.168.1.1 is valid, but 256.0.0.1 is not.
Strings like " bbaaa ", " bbaa ", " baa " or " a " are part of the language L.

د

`\b\d{1,3}\.\d{1,3}\.\d{1,3}\.\d{1,3}\b`

Regular Expression

Javascript

flags

`/\b\d{1,3}\.\d{1,3}\.\d{1,3}\.\d{1,3}\b/gm`

2 matches

Test String

Passwords like Strong#Pa\$\$w0rd or SecureP@ssw0r!d are examples of strong passwords.
The IP address 192.168.1.1 is valid, but 256.0.0.1 is not.
Strings like "bbaaaa", "accc", or "abbccc" are part of the language L.

ه

bbaaaa

bbaa

baa

a

b

$(bb^*)a^*a \mid [ab]^+$

`/(bb*)a*a | [ab]^+/gm`

10 matches

Test String

Passwords like Strong#Pa\$\$w0rd or SecureP@ssw0r!d are examples of strong passwords.
The IP address 192.168.1.1 is valid, but 256.0.0.1 is not.
Strings like " bbbaaa ", " bbaa ", " baa " or " a " are part of the language L.

The quick brown fox jumps over the lazy dog.

For academic inquiries, please contact professor@example.edu or student@university.ac.uk.

Passwords like Strong#Pa\$\$w0rd or SecureP@ssw0r!d are examples of strong passwords.

The IP address 192.168.1.1 is valid, but 256.0.0.1 is not.

Strings like " bbbaaa ", " bbaa ", " baa " or " a " are part of the language L.

2. پیکره بی جن خان، در آزمایشگاه زبان شناسی دانشگاه تهران نگهداری می شود. این پیکره، از برخی اخبار روزنامه ها و متون معمولی جمع آوری شده است. یکی از ویژگی های این پیکره این است که هر سند در این مجموعه دارای یک عنوان می باشد. به عنوان مثال، اسناد تحت عناوین (سیاسی، فرهنگی، اقتصادی) دسته بندی شده اند. در این پیکره **4300** عنوان مختلف وجود دارد. این عنوان ها یک محیط آزمایشی مورد دلخواه برای خوشه بندی و مقوله بندی و غیره را تولید می کند. این پیکره شامل **2598215** واژه و **550** برچسب می باشد که به طور دستی برچسب زده شده است. در عملیات برچسب زنی از عناوین متون صرف نظر شده است. زیرا هدف، بدست آوردن یک نرم افزار برچسب زننده خودکار است

هر برچسب در این مجموعه از یک ساختار سلسله مراتبی پیروی می کند. بخشهایی از نام برچسب که در ابتدای نام آن قرار دارند، بیان کننده توصیف کلی تری از آن برچسب می باشند. در ابتدای برچسب مقوله های اصلی مشخص می شوند، بخشهایی که در انتهای نام برچسب قرار دارند، توصیف جزئی تر در مورد آن برچسب هستند. یعنی سایر ویژگی های مقوله های اصلی قرار می گیرند. مثال برچسب **N_PL_LOC** سه سطح در ساختار سلسله مراتبی می باشد. سطح اول

N مشخص کننده اسم می باشد. سطح دوم **PL** مشخص کننده نوع جمع می باشد و سطح سوم **LOC** مشخص کننده مکان می باشد.

پیکره درختی وابستگی فارسی اوپسالا (**UPDT**) مجموعه‌ای است از جملات فارسی که در آن روابط نحوی کلمات بر مبنای دستور وابستگی مشخص شده است. این پیکره که در دانشگاه اوپسالا سوئد تهیه شده است، حاوی **6000** جمله برگرفته از پیکره فارسی اوپسالا (**UPC** - نسخه‌ای تغییر یافته از پیکره بی جن خان) می باشد و بر اساس قالب **conll** و طرح برچسب زنی **Stanford Typed Dependencies** تهیه شده است. ناشر این پیکره دپارتمان زبان شناسی و فیلولوژی، دانشگاه اوپسالا، سوئد است.

3. WordNet و FarsNet پایگاه‌های واژگانی هستند که کلمات را در روابط معنایی سازماندهی می کنند و اطلاعات ارزشمندی درباره معانی کلمات، مترادف‌ها، متضادها و سایر ویژگی‌های واژگانی ارائه می دهند. در اینجا یک مرور کلی از هر یک و برنامه های آنها آورده شده است :

1. WordNet :

WordNet یک پایگاه داده واژگانی از اسامی، افعال، صفت ها و قیده‌های انگلیسی است که به صورت **synsets** (مجموعه ای از مترادف ها) سازماندهی شده اند. هر **synset** یک مفهوم متمایز را نشان می دهد و از طریق روابط معنایی مختلف مانند **hypernym** ها (اصطلاحات وسیع تر)، هیپونیم ها (اصطلاحات محدودتر)، مرونیم ها (روابط جزئی-کل) و هولونیم ها (روابط کل جزئی) به مجموعه های دیگر مرتبط می شود.

برنامه های کاربردی:

- پردازش زبان طبیعی **WordNet (NLP)**: به طور گسترده در کارهایی مانند طبقه بندی متن، تجزیه و تحلیل احساسات و بازیابی اطلاعات استفاده می شود.
- ترجمه ماشینی: با ارائه معادل های معنایی برای کلمات در زبان های مختلف به بهبود دقت سیستم های ترجمه ماشینی کمک می کند.
- بازیابی اطلاعات **WordNet**: با گرفتن روابط معنایی بین کلمات، به نمایه سازی و بازیابی اسناد کمک می کند و دقت جستجو را افزایش می دهد.

مثال:

کلمه "سگ" را در نظر بگیرید. در **WordNet**، آن را به عنوان یک **synset** همراه با مترادف های آن (به عنوان مثال، "سگ") و مفاهیم مرتبط مانند ابرنام (به عنوان مثال، "حیوان")، مترادف (به عنوان مثال، "توله سگ") و مترونیم ها (به عنوان مثال، "دم" نشان داده می شود.)

1. FarsNet :

FarsNet یک پایگاه واژگانی مشابه **WordNet** است اما به طور خاص برای زبان فارسی (فارسی) طراحی شده است. حاوی اطلاعات معنایی در مورد کلمات فارسی از جمله مترادف، متضاد، ابرنام، مترادف و سایر روابط معنایی است.

برنامه های کاربردی:

- پردازش زبان فارسی **FarsNet** : برای کارهای مختلف **NLP** در زبان فارسی، از جمله تجزیه و تحلیل احساسات، تشخیص موجودیت نام گذاری شده و خلاصه سازی متن بسیار مهم است.
- کاربردهای بین زبانی: با ارائه معادل های معنایی، بازیابی اطلاعات بین زبانی و ترجمه ماشینی بین فارسی و سایر زبان ها را تسهیل می کند.
- فرهنگ نویسی و آموزش زبان: فارس نت به عنوان منبعی ارزشمند برای فرهنگ نویسان، معلمان زبان و زبان آموزان است که به گسترش و درک واژگان کمک می کند.

مثال:

کلمه فارسی «خرس» (خرس) را در نظر بگیرید که به معنای «خرس» است. در فارس نت، این کلمه به صورت ترکیبی همراه با مترادف ها (مثلاً «خرس قهوه ای» برای خرس قهوه ای)، متضادها (مثلاً «پری»)، ابرنامها (مثلاً «جانور») و سایر مفاهیم مرتبط نشان داده می شود.

به طور خلاصه، **WordNet** و **FarsNet** هر دو نقش تعیین کننده ای در **NLP**، فناوری زبان و تحقیقات زبانی با ارائه اطلاعات معنایی غنی در مورد کلمات به ترتیب به زبان انگلیسی و فارسی ایفا می کنند.

4. ابزار NLTK (طبیعی پردازش زبان) یکی از پرکاربردترین و مفیدترین ابزارهای استفاده شده در زمینه پردازش زبان های طبیعی است. این ابزار دارای مجموعه ای از دیتاست ها و ابزارهاست که به تحلیل، پردازش و استخراج اطلاعات از متون مختلف کمک می کند. در زیر، سه مورد از دیتاست ها و سه مورد از ابزارهای مهم **NLTK** را معرفی و کاربردهای آنها را توضیح می دهیم:

دیتاست ها:

1. دیتاست **WordNet** :

- **WordNet** یک دیتاست معروف در زمینه هم معنی ها (synonyms)، هم زمان ها (antonyms) و روابط معنایی بین کلمات است.
- کاربردهای آن شامل پردازش معنایی کلمات، مترادف یابی، ساختاردهی و مدل سازی زبانی است.

2. دیتاست Gutenberg Corpus :

- این دیتاست شامل مجموعه‌ای از متون کلاسیک و عمومی است که از پروژه Gutenberg برداشته شده است.
- کاربردهای آن شامل آموزش مدل‌های زبانی، تحلیل متون تاریخی و ادبیاتی، و ایجاد مجموعه‌های آموزشی و آزمون‌ی است.

3. دیتاست Movie Reviews :

- این دیتاست شامل بررسی‌ها و نقدهای کاربران در مورد فیلم‌ها است.
- کاربردهای آن شامل ایجاد سیستم‌های تشخیص متن و احساسات (Sentiment Analysis)، تحلیل دیدگاه‌ها و ارزیابی کیفیت فیلم‌هاست.

ابزارها:

1. Tokenizer :

- این ابزار برای تجزیه متن به تکه‌های کوچکتر مانند کلمات یا جملات استفاده می‌شود.
- کاربردهای آن شامل تجزیه و تحلیل متن، پردازش زبانی، و پیش‌پردازش متون برای وظایف دیگر مانند تحلیل عاطفه است.

2. POS Tagger (Part-of-Speech Tagger) :

- این ابزار برای تشخیص نقش هر کلمه در یک جمله (مثلاً فعل، اسم، صفت و ...) استفاده می‌شود.
- کاربردهای آن شامل استخراج اطلاعات ساختار جملات، تحلیل گرامری، و ترجمه ماشینی است.

3. Named Entity Recognizer (NER) :

- این ابزار برای شناسایی و استخراج اسامی نهادها، مکان‌ها، افراد و سایر موجودیت‌های مهم از متن استفاده می‌شود.
- کاربردهای آن شامل استخراج اطلاعات از متون، تحلیل اخبار، و ایجاد پایگاه داده‌های نام‌گذاری شده است.